不使用RL，没有Reward model，直接使用人类偏好数据训练模型

优化目标：$\max_{\pi_\theta} E_{x\sim D}\, E_{y\sim\pi_\theta(y|x)}\left[r_\phi(x|y)\right] - \beta D_{KL}\left(\pi_\theta(y|x)\,\|\,\pi_{ref}(y|x)\right)$

$$= \max_{\pi} E_{x\sim D}\, E_{y\sim\pi(y|x)}\left[r(x,y) - \beta\log\frac{\pi(y|x)}{\pi_{ref}(y|x)}\right] = \min_{\pi} E_{x\sim D}\, E_{y\sim\pi(y|x)}\left[\log\frac{\pi(y|x)}{\pi_{ref}(y|x)} - \frac{1}{\beta}r(x,y)\right]$$

$$= \min_{\pi} E_{x\sim D}\, E_{y\sim\pi(y|x)}\left[\log\frac{\pi(y|x)}{\frac{1}{Z(x)}\pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r(x,y)\right)} - \log Z(x)\right]$$

∴如果 $\frac{1}{Z(x)}\pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r(x,y)\right)$ 可以写成分布，那么这一项就相当于KL散度

构造 $Z(x) = \sum_y \pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r(x,y)\right)$ ，$\frac{\pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r(x,y)\right)}{\sum_y \pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r(x,y)\right)}$ 相当于一个归一化操作，把分母变成了概率分布：$\pi^*(y|x) = \frac{1}{Z(x)}\pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r(x,y)\right)$

∴优化目标：$\min_{\pi} E_{x\sim D}\, E_{y\sim\pi(y|x)}\left[D_{KL}\left(\pi(y|x)\,\|\,\pi^*(y|x)\right) - \log Z(x)\right]$

∵ $Z(x)$ 与待优化 π 无关 ∴只看KL散度项，即两个分布相同时KL散度最小

∴ $\pi(y|x) = \pi^*(y|x) = \frac{1}{Z(x)}\pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r(x,y)\right)$

以上推导假设有 $r(x,y)$，实际上，$r(x,y)$ 需要训练成一个最优的 $r^*(x,y)$

∴ $\pi(y|x) = \pi^*(y|x) = \frac{1}{Z(x)}\pi_{ref}(y|x)\exp\left(\frac{1}{\beta}r^*(x,y)\right)$

得到了最优策略的显式解

但由于 $Z(x)$ 需要对一个 x 采样得到足够多 y，所以还不能用于优化

而且目前的表达式中还有 $r^*(x,y)$

$$r^*(x,y) = \beta\log\frac{\pi^*(y|x)}{\pi_{ref}(y|x)} + \beta\log Z(x)$$

所以可以直接训练一个 $r(x,y)$ 可以直接得到 $\pi^*(y|x)$

训练奖励模型：用偏好排序数据训练 — 只生成2个回答 / 生成 $k>2$ 个回答

GPT是将k个回答整理成 C_k^2 对回答实现统一，DPO一般统一处理

BT模型：只生成两个回答 <prompt x, chosen y_1, reject y_2>

用统计模型 Bradley-Terry (BT)

$P(y_1 > y_2) = \frac{e^{\lambda_{y_1}}}{e^{\lambda_{y_1}} + e^{\lambda_{y_2}}}$ λ_{y_i} 强度参数

$P(y_1 > y_2 | x) = \frac{e^{r(x,y_1)}}{e^{r(x,y_1)} + e^{r(x,y_2)}}$

奖励函数的优化目标 $L_R(r_\phi, D) = -E_{(x,y_w,y_l)\sim D}\left[\log P(y_w > y_l | x)\right]$

代入BT：$L_R(r_\phi, D) = -E_{(x,y_w,y_l)\sim D}\left[\log\frac{1}{1+\exp\left[-(r(x,y_w)-r(x,y_l))\right]}\right]$

$$= \underbrace{-E_{(x,y_w,y_l)\sim D}\left[\log\sigma\left[r(x,y_w) - r(x,y_l)\right]\right]}_{\text{GPT的奖励模型优化目标}}$$

$$\therefore L_R(r_\phi, D) = -E_{(x,y_w,y_l)\sim D}\left[\log\sigma\left[\beta\log\frac{\pi(y_w|x)}{\pi_{ref}(y_w|x)} - \beta\log\frac{\pi(y_l|x)}{\pi_{ref}(y_l|x)}\right]\right]$$

∴无需 reward model 即可得到优化目标

PT模型：对 $k>2$ 个回答

$$P(r|y_1\cdots y_k\ x) = \underbrace{\prod_{k=1}^{k}\frac{\exp\left[r(x,y_r(k))\right]}{\sum_{j=k}^{K}\exp\left[r(x,y_r(j))\right]}}$$ 在可选答案中选出第一名、第二名…的概率总和

同样可变为直接优化策略的loss形式